

Práctico 5 - Retorno de la Información

BBDD-2025

Ejercicio 0: Dé una definición general de recuperación de información (RI). ¿Qué involucra el retorno de la información cuando consideramos información en la Web?

Es el proceso de retornar documentos a partir de una colección de documentos en respuesta a una consulta.

Cuando consideramos información en la web, dicha colección no viene dada de antemano, se procesan sitios web y páginas web, que serán estos documentos.

Ejercicio 1: Supongamos que desea encontrar documentos que contengan al menos k de un conjunto dado de n palabras clave. Suponga también que dispone de un índice de palabras clave que le proporciona una lista (ordenada) de identificadores de documentos que contienen una palabra clave determinada. Dé un algoritmo eficiente para encontrar el conjunto de documentos deseado.

Ejercicio 2: Describa las componentes principales de un sistema de retorno de la información.

Ejercicio 3: ¿Qué es el modelo de espacio vectorial de retorno de la información? ¿Cómo se construye un vector para representar un documento?


Es un enfoque estadístico que analiza los documentos y los descompone en piezas para luego comparar dichas piezas con los términos de una consulta y retornar los documentos que la cumplan.

Este modelo representa los documentos con un vector de pares de dimensión n , donde cada término corresponde a una dimensión y cada dimensión tiene, además del término, un número para representar la presencia del término en dicho documento o la frecuencia de dicho término.

Las consultas también serán vectores de términos que se compararán con los vectores de los documentos y así estimar su similitud/relevancia. Para estimar esto puedo usar la frecuencia de cada término o TF-IDF, que indica que los términos que capturan la esencia del documento aparecen frecuentemente en este, pero en pocos documentos de la colección

Ejercicio 6: Reúna cinco documentos que contengan unas tres oraciones cada uno, y cada uno contiene algún contenido relacionado. Construya un índice invertido de todas las palabras clave de estos documentos.

1. Mi mamá cocina galletas en todos mis cumpleaños. A mi hermana no le gustan mucho pero a mí si. A veces hace de chocolate, y otras de vainilla.
2. Les dejo un tip para cocinar unas galletas geniales. Precaletar el horno en mínimo 5 minutos antes de meterlas. Espero les sirva!
3. No sabes cómo festejar tu cumpleaños? Te dejo una idea... Fiesta de disfraces!
4. Recomendán disminuir el consumo de azúcar en niños. Estudios dicen que 8 de cada 10 niños llevan meriendas altas en azúcar a la escuela todos los días. Entre las meriendas más recurrentes aparecen los alfajores y las galletas.
5. Mamás de una escuela organizan un taller de cocina para madres y niños. Será el 23 de Noviembre en horario de clases. Algunas recetas que se enseñarán: torta de chocolate, galletitas con chips.

Id	Term	Doc:Pos
1	Cocina/r	1:3, 2:5, 5:8
		

Ejercicio 7: Describa el proceso de construir el resultado de un pedido de búsqueda usando un índice invertido. Asuma las consultas son basadas en proximidad. ¿Cómo debe ser el índice invertido? Se usan sentencias *ADJ*, *PRE* y *NEAR*. Considerar el significado de estas sentencias de la filmina 6 del archivo sobre retorno de la información. Dar algoritmo de cómo se procesa cada una de las sentencias para dar una respuesta a una búsqueda.

- Para consultas basadas en proximidad el índice invertido debe especificar el documento dónde aparece el término y la posición.
- Para *ADJ*: los términos a buscar deben ser adyacentes. Busco dichos términos en mi índice invertido y chequeo que la posición del primero sea la posición - 1 o la posición + 1 del segundo.
- Para *PRE/n*: Busco el primer término en mi índice, guardo todos los docs y sus respectivas posiciones en dichos docs. Busco el segundo término, para cada igualdad en el numero de doc, chequeo que la posición sea, como máximo, posición + n de alguna de las apariciones del primer término en el documento que estoy analizando.
- Para *NEAR/n*: Busco el primer término que aparezca en mi índice. Guardo docs y posiciones. Busco el segundo. Para los que tengan igual número de doc que alguna aparicion del primer término, chequeo que su posición sea, como mínimo, posición - n y como maximo posición + n.

Luego de estas búsquedas, guardo cada número de doc que haya cumplido las condiciones y retorno dichos documentos.

Ejercicio 8: compare retorno de la información para un conjunto de archivos en su PC con retorno de la información en la web. Definir al menos 5 criterios de comparación en que son diferentes y construya una tabla para ello.

Criterios	Archivos Pc	web
colección de documentos	Esta dado (Acordado)	No esta dado (no acordado)
Indexado	invertido, con, al menos, núm de doc, en lista	invertido, con doc ID, frecuencia, posiciones, payload, en shards.
Búsquedas	Se secuenciale (las hago jo)	Muchas en simultaneo
Relevancia de los resultados	Dada por freq. del termino, TF-IDF	Se tiene en cuenta popularidad del sitio, pagerank
Contenido del resultado	Archivos	Enlaces

Ejercicio 9: ¿Cuál es la idea por detrás del algoritmo PageRank? ¿Tiene alguna limitación? ¿Qué se puede hacer para superarla?

La idea es medir la popularidad de un sitio web, y así asignarle más o menos relevancia a la hora de responder con él a una consulta. Se basa en la popularidad de las páginas que tienen como hiperenlace a la página analizada. Mientras más enlazada por otras páginas esté la página analizada, mayor importancia tendrá.

El PageRank de una página web es la probabilidad que tiene de ser visitada en algún punto del tiempo. Mientras más hiperenlaces en otras páginas apunten a ella, más probabilidad de ser visitada y por lo tanto, mas PageRank. Limitación: No tiene en cuenta términos de la consulta.

Solución: Juzgar la relevancia que tiene en ciertos tópicos de acuerdo a las palabras clave en el texto del áncora de los hiperenlaces a dicha página.

Ejercicio 10: enuncie 3 problemas que debe resolver un rastreador web.

Localizar y recolectar información en la web que sirva como colección de documentos donde hacer búsquedas.

Analizar internamente el contenido de una página.

Detectar contenido duplicado.

Filtrar páginas por calidad o spam.

Clasificar preliminarmente la página (inferir tema o categoría)

Ejercicio 11: Comparar un sistema de retorno de la información basado en relevancia con un sistema de BD relacional considerando los siguientes criterios:

- Datos
- Índices (similitudes y diferencias)
- Informaciones acerca de los datos que no son ni los datos ni los índices.
- Ordenamiento de los resultados de las consultas
- Inputs para procesar una consulta

Criterio	Sist. BD relacional	SRI
Datos	Estructurados	No estructurados
Índices	de árbol B+, aceleran la búsqueda	Invertidos, aceleran la búsqueda
Info de datos que no son datos ni índices	Metadatos, catálogo de la BD	Freq. de términos, peso, popularidad
Inputs p/ consulta	Operaciones SQL	Lenguaje natural, palabras clave, conectores proposicio- nales, expr. regulares
Ordenamiento de los resultados	Por claves Primarias, o puede explicitarse	Por relevancia, popularidad

PARCIAL (MODELO)

Ejercicio 4: Recuperación de la información: Responder:

1. Supongamos que queremos hacer búsquedas ordenadas por relevancia de documentos en una colección de documentos en mi disco rígido; asumir que se usa modelo de espacio vectorial e índices invertidos. Las consultas son booleanas. Dar significado de las componentes de las tuplas que van en una lista de índice invertido asociada a un término.
2. Listar los pasos para procesar una consulta basada en relevancia de documentos; es una colección que está en un disco rígido, se usa modelo de espacio vectorial, similitud de vectores para la relevancia, y consultas booleanas. Evitar pasos innecesarios.

1. Para cada término del índice invertido voy a tener una tupla con:
(Documento donde aparece, frecuencia, peso (TF-IDF))

.

2. Se analiza el vocabulario de la consulta y se arma el vector de consulta.
Para cada término se busca en qué documentos están usando el índice invertido.

Se procesa cada documento para ver si cumple dicha expresión booleana.

Se comparan los vectores de los documentos que cumplieron la expresión con el vector de la consulta, usando

función de similitud de vectores (pr ej. coseno del ángulo entre los vectores de la consulta y del doc).

Si dicha función da cerca de 1: vectores muy similares

si da cerca de cero: los vectores no tienen casi nada en común

si da -1: los vectores son opuestos

Se devuelven, por orden de relevancia (es decir, los que hayan dado más cerca de uno en la función de similitud primero), los documentos coincidentes.