

Simulación p-valor para el test Chi-cuadrado (discreto)

Simulaciones para el test chi-cuadrado

Parámetros especificados

La muestra original $\rightarrow$

$X_1=x_1, \dots, X_n=x_n$ de tamaño n

$$p\text{-valor} = P_{H_0}(T \geq t_0)$$

estimamos con una proporción

Algoritmo:

$$p\text{-valor} = 0$$

for i in range (Nsim):

generamos $y_1^{(i)}, y_2^{(i)}, \dots, y_m^{(i)}$ de la distribución F

calculamos $N_1^{(i)}, N_2^{(i)}, \dots, N_k^{(i)}$

$$\text{evaluamos } T: t^{(i)} = \sum_{j=1}^k (N_j^{(i)} - m \cdot p_j)^2 / (m \cdot p_j)$$

if $t^{(i)} \geq t_0$:

$$p\text{-valor} += 1$$

$$p\text{-valor} = p\text{-valor} / Nsim$$

frecuencias observadas.

En vez de generar la y_i , podemos generar los $N_k^{(i)}$ usando Binomiales:

Generar frecuencias observadas $N_1^{(i)}, N_2^{(i)}, \dots, N_k^{(i)}$

$y_1^{(i)}, y_2^{(i)}, y_3^{(i)}, \dots, y_{m-1}^{(i)}, y_m^{(i)}$

$$Y \in \{y_1, y_2, \dots, y_k\}$$

$$P(Y = y_j) = p_j$$

$$\left\{ \begin{array}{l} N_1^{(i)} = \text{Bin}(m, p_1) \\ N_2^{(i)} = \# \{ Y_s^{(i)} = y_2 \mid Y_s^{(i)} \neq y_1 \} \\ \quad = \text{Bin}(m - N_1^{(i)}, p_2 / (1 - p_1)) \\ N_3^{(i)} = \text{Bin}(m - N_1^{(i)} - N_2^{(i)}, \frac{p_3}{1 - p_1 - p_2}) \\ \vdots \\ N_k^{(i)} = m - N_1^{(i)} - N_2^{(i)} - \dots - N_{k-1}^{(i)} \end{array} \right.$$

$$P(Y^{(i)} = y_2 \mid Y^{(i)} \neq y_1) = \frac{p_2}{1 - p_1}$$

Simulaciones: parámetros no especificados

Muestra: $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ ←

Estimamos $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$, ←

Determina F_j con probabilidades $\hat{p}_1, \hat{p}_2, \dots, \hat{p}_k$; $P(X=y_j) = \hat{p}_j$

$$T = \sum_{j=1}^k \frac{(N_j - n \cdot \hat{p}_j)^2}{n \hat{p}_j} = t_0$$

Algoritmo

p-valor = 0

for i in range(Nsim):

• generamos $X_1^{sim}, X_2^{sim}, \dots, X_n^{sim}$ a partir de F

• estimamos $\hat{\theta}_1^{sim}, \hat{\theta}_2^{sim}, \dots, \hat{\theta}_m^{sim}$

$$t = \sum_{j=1}^k \frac{(N_j - n \cdot \hat{p}_j^{sim})^2}{n \cdot \hat{p}_j^{sim}}$$

if $t \geq t_0$:

p-valor += 1

p-valor = p-valor / Nsim.

Simulación p-valor para test de Kolmogorov-Smirnov (continuo)

$$D = \sup_{x \in \mathbb{R}} \{ |F(x) - F_e(x)| \} = \max_{1 \leq i \leq m} \left\{ F(x_{(i)}) - \frac{i-1}{n}, \frac{i}{n} - F(x_{(i)}) \right\}$$

• $X_1, X_2, \dots, X_m$

• $D = d$

• $P_{H_0}(D \geq d) = p\text{-valor} \leftarrow \text{simulaciones}$

der igual sobre qe distribución lo mismo

pvalor = 0

for i in range(Nsim):

generar $X_1, X_2, \dots, X_m \sim F$

ordenar $X_{(1)}, X_{(2)}, \dots, X_{(m)}$

dsim = D(muestra generada)

if dsim $\geq d$:

pvalor += 1

pvalor = pvalor / Nsim

=> en vez de generar $X_i \sim F$
genero $U_i \sim U(0,1)$

Test de Kolmogorov-Smirnov (parámetros especificados)

1) $X_1 = x_1, X_2 = x_2, \dots, X_m = x_m$

2) Planteamos H_0) los datos provienen de la distribución F

3) Calculamos $d = \max_{1 \leq i \leq m} \left\{ F(x_{(i)}) - \frac{i-1}{n}, \frac{i}{n} - F(x_{(i)}) \right\}$

4) p-valor = $P(D \geq d)$

Uniforme

pvalor = 0

for i in range(Nsim):

generar $U_1, U_2, \dots, U_m \sim U(0,1)$

ordenar $U_{(1)} < U_{(2)} < \dots < U_{(m)}$

dsim = $\max_{1 \leq i \leq m} \left\{ U_{(i)} - \frac{i-1}{m}, \frac{i}{m} - U_{(i)} \right\}$

if dsim $\geq d$: pvalor += 1

pvalor = pvalor / Nsim

Test de Kolmogorov - Smirnov

Parámetros no especificados

1) $X_1 = x_1, X_2 = x_2, \dots, X_m = x_m$

2) H_0) Los datos provienen de una distribución F_1 con parámetros $\theta_1, \dots, \theta_m$ estimados a partir de la muestra. Esto da una $F_{\hat{\theta}}$.

3) Estadístico: $D = \max_{1 \leq i \leq m} \left\{ F_{\hat{\theta}}(x_{(i)}) - \frac{i-1}{n}, \frac{i}{n} - F_{\hat{\theta}}(x_{(i)}) \right\}$

4) $p\text{-valor} = P_{H_0}(D \geq d) \rightarrow$ varias opciones p/ calculario

p-valor

1) Simular utilizando muestras de uniformes.

Este resultado es una estimación gruesa del p-valor.

Si el valor obtenido es cercano al valor de rechazo, mejor utilizar 2)

2) $p\text{-valor} = 0$

for i in range(N_{sim}):

generar $[X_1^s, X_2^s, \dots, X_m^s]$ con $F_{\hat{\theta}}$

estimar $\theta_1, \theta_2, \dots, \theta_m$ a partir de $X_1^s, X_2^s, \dots, X_m^s \rightarrow$ esto determina $F_{\hat{\theta}}^{sim}$

$$d_{sim} = \max_{1 \leq i \leq m} \left\{ F_{\hat{\theta}}^{sim}(X_{(i)}^s) - \frac{i-1}{n}, \frac{i}{n} - F_{\hat{\theta}}^{sim}(X_{(i)}^s) \right\}$$

if $d_{sim} \geq d$:

$p\text{-valor} += 1$

$$p\text{-valor} = p\text{-valor} / N_{sim}$$